

Clasificación automática de transcripciones médicas por especialidad

Problema y Contexto

La documentación clínica es un pilar de la atención médica moderna: diariamente se generan transcripciones que registran procedimientos, diagnósticos, tratamientos y evolución de pacientes. Sin embargo, clasificar manualmente estas transcripciones por especialidad médica es un proceso lento, costoso y propenso a inconsistencias, lo que dificulta la organización y recuperación eficiente de la información en sistemas de historias clínicas electrónicas. Para estudiar este problema, se utilizará el dataset mtsamples, con 4,999 registros distribuidos en 39 especialidades, lo cual introduce retos representativos del mundo real: fuerte desbalance de clases (pocas especialidades concentran la mayoría de las muestras), variación notable en longitud de los documentos y terminología especializada que difiere entre especialidades.

Pregunta de negocio

¿Podemos automatizar la clasificación de transcripciones médicas por especialidad de forma que reduzca el etiquetado manual y mantenga un desempeño aceptable pese al desbalance de datos?

Alcance del proyecto

El objetivo del proyecto es diseñar e implementar un sistema reproducible de clasificación automática de transcripciones por especialidad, acompañado de un pipeline MLOps que garantice trazabilidad y operación consistente: versionamiento de datos y modelos, seguimiento de experimentos y métricas, despliegue automatizado y monitoreo del rendimiento. Con ello, se busca una solución práctica y mantenible para organizar transcripciones médicas a escala, con criterios claros de evaluación y buenas prácticas de ingeniería aplicadas al aprendizaje automático.

Descripción del conjunto de datos

Para el desarrollo del modelo de clasificación, se seleccionó el dataset de Transcripciones Médicas (fuente: [Kaggle/mtsamples](https://kaggle.com/mtsamples)). El dataset cuenta con 1962 registros luego de la limpieza, distribuidas en 10 especialidades filtradas por representatividad, este fue el cambio principal y fue debido a que solo 10 de las 39 especialidades tienen 50 o más muestras después de eliminar duplicados, aun así, se mantiene un gran desbalance entre las clases.

Modelos desarrollados

En esta fase realizamos el entrenamiento y prueba de dos modelos con aproximaciones diferentes, pero utilizando una vectorización TF-IDF con 10,000 características y usando unigramas y bigramas:

- **XGBoost:** Este es un modelo robusto en alta dimensionalidad y se capturan las interacciones no lineales entre características después del TF-IDF, partimos de un modelo con hiperparámetros; `n_estimators=200`, `max_depth=6`, `learning_rate=0.1`, `subsample=0.8` y `colsample_bytree=0.8`
- **Logistic Regression:** Siendo el modelo lineal de referencia, llegando a ser incluso superior a los árboles en clasificación de texto, los hiperparámetros del modelo base fueron; `C=1.0`, `max_iter=1000`, `solver=lbfgs` `class_weight=balanced`.

Se definió un protocolo de entrenamiento y evaluación reproducible con partición estratificada de datos para preservar la proporción de clases en cada subconjunto. La división utilizada fue 80% entrenamiento, 10% validación y 10% prueba, con `random_state = 42`

Con estos modelos bases obtuvimos los siguientes resultados:




Ilustración 1: F1 Score en cada clase para cada modelo




Ilustración 2: Métricas generales de cada modelo

Evaluación de modelos:

Para la evaluación de los modelos se realizaron varios experimentos que registramos en MLflow con el fin de encontrar los mejores hiperparámetros y escoger el modelo adecuado.

Configuración de la Infraestructura en AWS EC2

Se utilizó una instancia t2.small con Ubuntu 24.04 en Amazon Web Services como servidor centralizado de tracking. El acceso se gestionó mediante reglas de seguridad en el Security Group, habilitando el puerto 5000 para el tráfico del servidor y el puerto 22 para administración vía SSH.

Instance summary for i-09dad7a98353ab18e (MLflow-Traking-Server) [Info](#)

Updated about 2 hours ago

Instance ID
i-09dad7a98353ab18e

IPv6 address
-

Hostname type
IP name: ip-172-31-27-80.ec2.internal

Answer private resource DNS name
IPv4 (A)

Auto-assigned IP address
98.81.91.42 [Public IP]

IAM role
-

IMDSv2
Required

Operator

Public IPv4 address
98.81.91.42 | [open address](#)

Instance state
Running

Private IP DNS name (IPv4 only)
ip-172-31-27-80.ec2.internal

Instance type
t2.small

VPC ID
vpc-0884a94d0232d589f

Subnet ID
subnet-05b8a5c548bd9fd44

Instance ARN
arn:aws:ec2:us-east-1:874015532167:instance/i-09dad7a98353ab18e

Private IPv4 addresses
172.31.27.80

Public DNS
ec2-98-81-91-42.compute-1.amazonaws.com | [open address](#)

Elastic IP addresses
-

AWS Compute Optimizer finding
Opt-in to AWS Compute Optimizer for recommendations. | [Learn more](#)

Auto Scaling Group name
-

Managed
false

Ilustración 3: Detalles de la instancia EC2

sg-01ac2c20644a10ad4 - launch-wizard-7 [Actions](#)

Details

Security group name
launch-wizard-7

Security group ID
sg-01ac2c20644a10ad4

Description
launch-wizard-7 created 2026-02-21T17:04:28.027Z

VPC ID
vpc-0884a94d0232d589f

Owner
874015532167

Inbound rules count
2 Permission entries

Outbound rules count
1 Permission entry

Inbound rules | Outbound rules | Sharing | VPC associations | Related resources - new | Tags

Inbound rules (2)

Search

Name	Security group rule ID	IP version	Type	Protocol	Port range	Source	Description
-	sgr-0e7eafe66fa9f0d97	IPv4	Custom TCP	TCP	5000	0.0.0.0/0	-
-	sgr-016ca336999eab487	IPv4	SSH	TCP	22	0.0.0.0/0	-

Ilustración 4: Configuración del grupo de seguridad

Integración del Pipeline de Entrenamiento Local

El script de entrenamiento src/train.py fue modificado para incluir el ciclo de vida de MLflow, encapsulando los modelos de XGBoost y Regresión Logística. La comunicación se estableció configurando la variable de entorno MLFLOW_TRACKING_URI apuntando a la IP pública de la instancia EC2, permitiendo que un equipo local realizara el cómputo pesado mientras la nube registraba la trazabilidad.

```

danie@DANIE MINGW64 ~/MAIA/Proyecto de grado/W4/mlops-uniandes-project (main)
$ python -m src.train
Dataset: 1962 registros, 10 clases
2026/02/21 12:59:46 INFO mlflow.tracking.fluent: Experiment with name 'Medical_Transcriptions_Classification' does not exist.
Creating a new experiment.


Iniciando Tracking de MLflow en: http://98.81.91.42:5000
XGBoost - Acc: 0.8372, F1: 0.6716
2026/02/21 13:00:23 WARNING mlflow.models.model: 'artifact_path' is deprecated. Please use 'name' instead.
$ View run XGBoost_TFIDF at: http://98.81.91.42:5000/#/experiments/1/runs/2f24ef57abf9469282143eee106fdaf4
$ View experiment at: http://98.81.91.42:5000/#/experiments/1
C:\Users\danie\MAIA\Proyecto de grado\W4\mlops-uniandes-project\venv\Lib\site-packages\sklearn\linear_model\_logistic.py:1184:
FutureWarning: 'n_jobs' has no effect since 1.8 and will be removed in 1.10. You provided 'n_jobs=-1', please leave it unspecified.
  warnings.warn(msg, category=FutureWarning)
LogReg - Acc: 0.9008, F1: 0.8245
2026/02/21 13:00:36 WARNING mlflow.models.model: 'artifact_path' is deprecated. Please use 'name' instead.
2026/02/21 13:00:37 WARNING mlflow.sklearn: Saving scikit-learn models in the pickle or cloudpickle format requires exercising
caution because these formats rely on Python's object serialization mechanism, which can execute arbitrary code during deseri
alization. The recommended safe alternative is the 'skops' format. For more information, see: https://scikit-learn.org/stable/
model_persistence.html
$ View run LogReg_TFIDF at: http://98.81.91.42:5000/#/experiments/1/runs/e4aa8727ebd84e46be14921f29f0b9c5
$ View experiment at: http://98.81.91.42:5000/#/experiments/1

Modelos guardados en models
(venv)
  
```

Ilustración 5: Tracking del entrenamiento en MLflow

Registro de Experimentos y Comparación de Modelos

Se creó el experimento *Medical_Transcriptions_Classification*. En la interfaz de MLflow se evidencia el registro automático de hiperparámetros (como *learning_rate* y *n_estimators*) y métricas de desempeño (Accuracy y F1-Score) para cada ejecución. Esta tabla permite una auditoría clara de qué versión del modelo ofrece el mejor rendimiento antes de cualquier despliegue.



Run Name	Created	Dataset	Duration	Source	Models
LogReg_TFIDF	1 hour ago	-	69s	CLIUser...	models_logreg
XGBoost_TFIDF	1 hour ago	-	480s	CLIUser...	models_xgboost

Ilustración 6: Registro de experimentos en MLflow

Análisis de Sensibilidad y Variación de Parámetros

Cada corrida registró automáticamente sus parámetros y métricas en el experimento centralizado *Medical_Transcriptions_Classification*, facilitando una auditoría completa del desempeño. En la vista general de "Runs", se evidencia cómo la variación de hiperparámetros críticos, como la fuerza de regularización (C) en la Regresión Logística y la profundidad máxima (max_depth) en XGBoost, impacta directamente en la precisión del modelo. Este registro sistemático permitió identificar que la configuración de LogReg con un umbral de muestras de 100 alcanzó el desempeño más alto del proyecto con un Accuracy de 0.94.

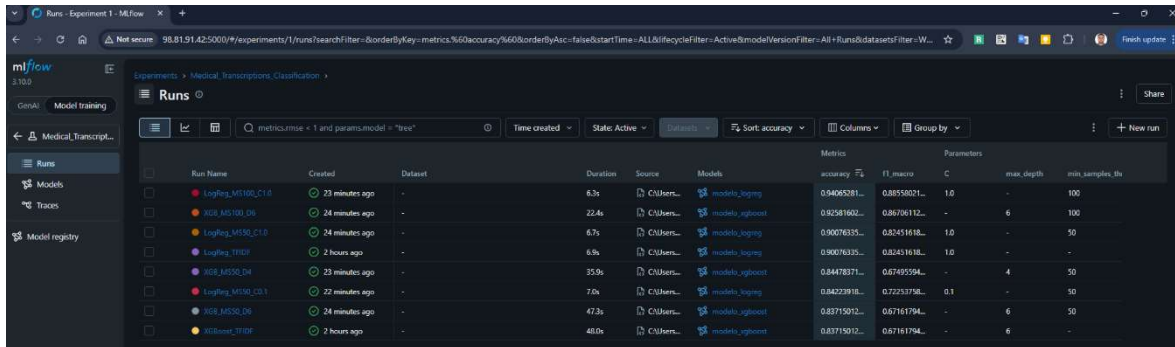


Ilustración 7: Registro de experimentos variando los hiperpárametros de los modelos

Para profundizar en la comprensión del modelo, se utilizó la herramienta de Parallel Coordinates Plot de MLflow, la cual permite visualizar las correlaciones entre múltiples variables de entrada y el éxito de la clasificación. En este gráfico se observa claramente la trayectoria de los experimentos más exitosos, revelando que el modelo de Regresión Logística presenta una mayor estabilidad y sensibilidad positiva ante el balanceo de clases y la regularización moderada en comparación con los modelos basados en árboles. Finalmente, la sección de Artifacts de cada ejecución garantiza la trazabilidad total, almacenando no solo las métricas, sino también los binarios del modelo (.pkl) y los requisitos de entorno, asegurando que cualquier resultado reportado pueda ser replicado y verificado bajo los estándares de gobernanza de MLOps.

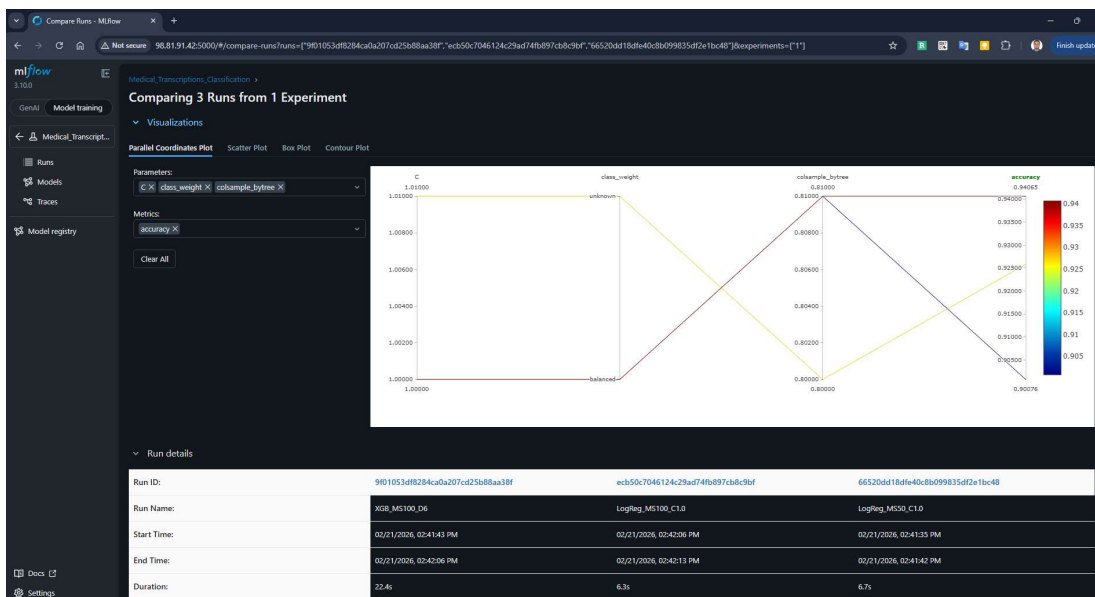


Ilustración 8: Comparación y graficas de los resultados

Gestión de Artefactos y Trazabilidad Final

Más allá de los números, se verificó el almacenamiento de artefactos dentro de cada "Run". MLflow guarda automáticamente el archivo del modelo serializado (.pkl), el diccionario de datos y las dependencias necesarias (requirements.txt), garantizando que cualquier experimento pueda ser replicado exactamente en el futuro.

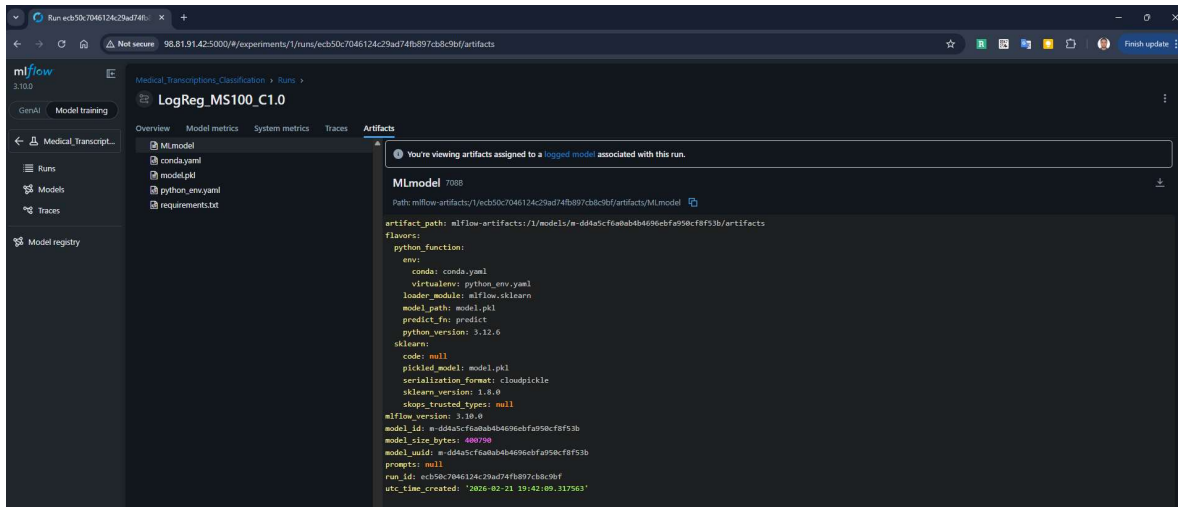


Ilustración 9: Trazabilidad de los artefactos en MLflow

Conclusiones de los modelos

Como resultado de la experimentación, se selecciona el modelo *LogReg_MS100_C1.0* para la siguiente fase del proyecto, dado que presenta el mejor balance entre precisión (0.94) y estabilidad ante el ruido en las transcripciones médicas, superando el riesgo de sobreajuste observado en las versiones más profundas de XGBoost.

Tablero Desarrollado

Como parte integral de la solución propuesta para automatizar la categorización de notas clínicas, se desarrolló una aplicación web interactiva utilizando **Streamlit**, soportada por un backend robusto en **FastAPI**. Esta arquitectura permite a los especialistas médicos interactuar con el modelo de Procesamiento de Lenguaje Natural (NLP) en tiempo real, sin requerir conocimientos técnicos previos. El sistema carga en memoria los artefactos del modelo con mejores resultados de los experimentos (LogReg_MS100_C1.0), garantizando inferencias de alta precisión.

El tablero fue diseñado bajo principios de usabilidad clínica y se divide en dos secciones principales:

Pestaña 1: Home (Contexto y Ética) Esta sección funciona como la página de inicio y aterrizaje de la herramienta. Sus características principales son:

- **Métricas del Modelo:** Presenta visualmente el rendimiento real del modelo en producción (94.0% de Precisión, 1,962 transcripciones de entrenamiento, 10 especialidades), generando confianza en el usuario.
- **Instrucciones de uso:** Guía paso a paso sobre cómo interactuar con el clasificador.
- **Descargo de Responsabilidad (Disclaimer Médico):** Funcionalidad crítica de diseño orientada a productos de tecnología en salud (*HealthTech*). Advierte formalmente en la interfaz que la herramienta emite estimaciones probabilísticas como apoyo analítico y bajo ninguna circunstancia sustituye el diagnóstico clínico de un profesional.

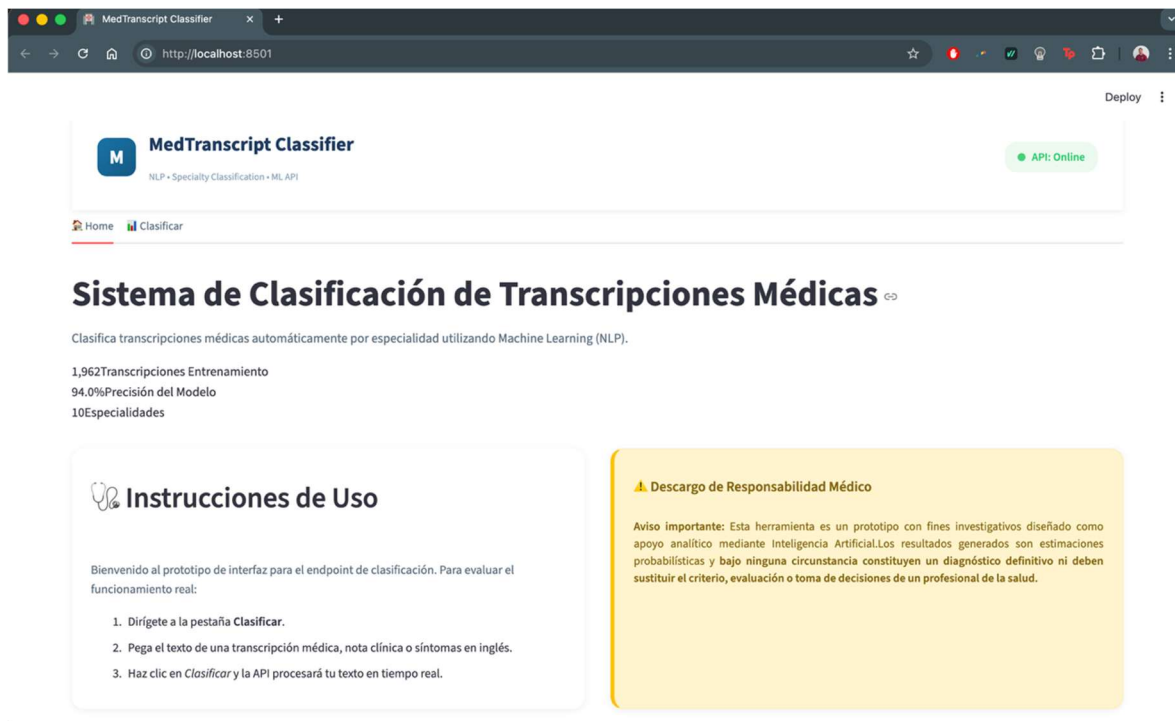



Ilustración 10: Vista de Pestaña Home

Pestaña 2: Clasificar (Inferencia en Tiempo Real) Es el núcleo operativo del aplicativo, donde se realiza la interacción directa con el endpoint de inferencia /predict (vía método POST). Sus funcionalidades incluyen:

- **Ingreso de información:** Un área de texto libre (Text Area) optimizada para que el especialista pegue transcripciones médicas, síntomas o notas clínicas extensas.
- **Procesamiento y conexión API:** Al ejecutar la acción, el frontend consume la API local, enviando el texto para su vectorización (TfidfVectorizer) y clasificación matemática, recibiendo la respuesta en formato JSON.
- **Feedback visual y de resultados:** Despliega la "Especialidad predicha" principal de forma destacada en pantalla.
- **Interpretabilidad (Niveles de confianza):** Para evitar un modelo de "caja negra", el sistema muestra el porcentaje de confianza de la predicción mediante barras dinámicas. Adicionalmente, desglosa visualmente el **Top 3 de especialidades secundarias** con sus respectivas probabilidades. Esto permite al médico evaluar alternativas si las especialidades tienen un margen de diferencia estrecho.



The screenshot shows a web browser at `http://localhost:8501` displaying the **MedTranscript Classifier** application. The interface is divided into two main sections: **Entrada** (Input) and **Resultados** (Results).

Entrada: Contains a text area with a sample medical report: "CT OF THE BRAIN WITHOUT CONTRAST. 45-year-old male with severe headache and dizziness. Axial images of the brain were obtained without the administration of intravenous contrast. FINDINGS: There is no evidence of acute intracranial hemorrhage, mass effect, or midline shift. The ventricles and sulci are normal in size and configuration for the patient's age. The basal cisterns are patent. No acute osseous abnormalities are seen. IMPRESSION: Normal unenhanced CT scan of the brain. No acute intracranial abnormality." Below the text area are two buttons: **Clasificar** (red) and **Limpiar** (white).

Resultados: Displays the classification results. At the top, it shows "Especialidad predicha" (Predicted Specialty) as **Radiology** in a blue button. Below this, a "Confianza del modelo" (Model Confidence) bar shows 83%. Further down, "Top 3 especialidades" (Top 3 specialties) are listed with their respective confidence levels: Radiology (83%), Surgery (5%), and Urology (4%).

Ilustración 11: Vista de Clasificador

Repositorio del proyecto

<https://github.com/wiflore/mlops-uniandes-project>

Reporte de Trabajo en equipo

Actividad	Desarrollada por
Problema, contexto, alcance y descripción del conjunto de datos	Todos
Creación de notebooks y modelos iniciales	William Flores
Búsqueda de hiperparámetros y registro de experimentos en MLflow	Daniel Caro
Empaquetamiento y serialización	Anderson Rodríguez
Diseño y creación de tablero	Andrés Romero y Nicolas Rios
Redacción del reporte	Nicolas Rios

Historial de commits del proyecto

<https://github.com/wiflore/mlops-uniandes-project/commits/main/>